

Fusión de sensores para estimar la orientación de un vehículo autónomo a escala, mediante el filtro de Kalman

Ingeniería Electromecánica con orientación electrónica

Erid Eulogio Pacheco Viana - 45990

Resumen— El presente artículo trata sobre la fusión de sensores para estimar la orientación de un vehículo autónomo a escala, utilizando el filtro de Kalman. Específicamente se realizó la fusión de sensores (acelerómetro, giroscopio y magnetómetro) con el fin de obtener estimaciones precisas de la orientación para la correcta navegación del vehículo, que se utilizó para una competencia. Se implementaron métodos de calibración (para el acelerómetro y giroscopio) con un enfoque práctico, para que pueda ser implementado antes del inicio de la carrera en tiempo real. Se simuló el filtro de Kalman para determinar la influencia de la variación de los parámetros que intervienen en las ecuaciones del filtro de Kalman. Se mejoró la respuesta de la instrumentación a las perturbaciones, lo que lleva a una estimación adecuada de la orientación.

Palabras clave— Filtro de Kalman (*Kalman filter*), fusión de sensores (*sensor fusion*).

I. INTRODUCCIÓN

LA fusión de sensores combina lecturas de diferentes sensores para obtener información con menos incertidumbre que la información obtenida por cada sensor individual. Esto permite aumentar la supresión de ruido y la precisión del sistema de medición.

Este trabajo de investigación se desarrolla a partir de la necesidad de obtener estimaciones precisas de la orientación para la navegación de un vehículo autónomo con sensores de bajo costo.

Los algoritmos de navegación para vehículos autónomos, requieren datos precisos de posición y orientación [1], para conseguir esto, de deben usar sensores de alta calidad, que generalmente son costosos y de difícil acceso. Esta precisión requerida, se puede conseguir con la fusión de sensores, en donde los datos provenientes de distintas fuentes son combinados para obtener la apropiada calidad de las mediciones de las variables que deben ser procesadas.

En el presente trabajo, la forma de navegación básica será la inercial, apoyado por el uso de un sensor auxiliar, para tener una referencia de orientación absoluta, y de esta manera, evitar errores acumulativos.

La navegación inercial se desarrolló a mediados del siglo XX

para la guía de misiles y fue mejorado mediante la Guerra fría como una tecnología para la guía de misiles nucleares de largo alcance. Sus primeras aplicaciones fueron militares, tales como sistemas de guías para misiles balísticos autónomos, barcos y aeronaves militares, pero la tecnología pronto se extendió a aplicaciones no militares como la navegación de aviones comerciales [1].

II. NAVEGACIÓN

A. El problema de la navegación y su solución

Según [1], el propósito de la navegación es dirigir el movimiento de vehículo para llegar a un destino determinado. Una parte importante de la navegación es determinar la posición y orientación del vehículo con relación al destino.

La solución a este problema, generalmente requiere observaciones o mediciones de algún tipo y poder usar esa información para determinar su posición y orientación con respecto a su destino.

B. Formas básicas de navegación

Según [1], podemos mencionar cinco formas básicas en las que un vehículo puede navegar:

- Pilotaje, que esencialmente se basa en el reconocimiento de puntos de referencia para saber dónde y cómo está orientado.
- Navegación por estima (Dead reckoning), que se basa en el reconocimiento de puntos de referencia para saber su posición y orientación y cierta estimación de la distancia recorrida.
- Navegación astronómica, usando el tiempo y los ángulos entre objetos celestes locales verticales y conocidos (por ejemplo, el sol, la luna, los planetas, las estrellas) para estimar la orientación, la latitud y la longitud.
- Radionavegación, que se basa en fuentes de frecuencia de radio con características de señal conocidas y ubicación conocida. Los sistemas de navegación global por satélite (GNSS por sus siglas en inglés, Global Navigation Satellite Systems) utilizan balizas en satélites para este propósito.
- Navegación inercial, que se basa en conocer su posición, velocidad y orientación iniciales y, a partir de ese momento,

medir sus velocidades, orientación y aceleraciones. Es la única forma de navegación que no se basa en referencias externas.

III. SENSORES UTILIZADOS PARA LA NAVEGACIÓN

Un sensor es un dispositivo que, a partir de la energía del medio donde se mide, da una señal de salida transducible (convierte una señal de una forma física a otra) que es función de la variable medida [2].

A. Acelerómetro

Un acelerómetro es un dispositivo que mide aceleraciones. Existen diferentes técnicas utilizadas para lograrlo, entre las más comunes se encuentran el uso de sistemas masa-resorte combinados con mediciones de capacitancia, sensores piezoeléctricos que miden la presión ejercida por una masa inercial y hasta algunos que utilizan la convección térmica del aire [3]. En [1] se pueden encontrar los tipos básicos de acelerómetros clasificados por su principio de funcionamiento.

B. Giroscopio

Los giroscopios son sensores para medir la rotación. Los giroscopios de velocidad miden la velocidad de rotación, y los giroscopios de desplazamiento (también llamados giroscopios de ángulo completo) miden el ángulo de rotación acumulado [1]. En [1] se pueden encontrar los tipos básicos de giroscopios clasificados por su principio de funcionamiento.

C. Magnetómetro

El magnetómetro es un tipo de sensor que mide la fuerza y la dirección del campo magnético local. El campo magnético medido será una combinación del campo magnético terrestre y cualquier campo magnético creado por objetos cercanos [4].

D. Calibración de sensores

Según [6], la calibración de sensores es el proceso de estimar la relación entre las entradas y las salidas de los sensores. Tiene como propósito convertir las salidas del sensor a entradas equivalentes, de modo que un valor de salida se pueda volver a convertir en unidades de aceleración de entrada o unidades de velocidad de rotación (casos del acelerómetro y giroscopio) para su uso en navegación. Entre los errores más comunes que requieren calibración o compensación se encuentran:

- Sesgo del sensor, que equivale a la salida del sensor cuando no hay entrada.
- Factor de escala del sensor, que es la relación entre la variación de salida y la variación de entrada.
- Errores de desalineación del eje de entrada del sensor.

Para muchas prácticas (incluyendo la navegación), es suficiente usar un factor de escala y sesgo para cada eje y quizás dos componentes de los ángulos de desalineación del eje de entrada [1]. Teniendo en cuenta esto, podemos definir los modelos que serán utilizados para la calibración de los sensores que serán utilizados.

Según [4], para el caso del magnetómetro, el sensor puede estar sometido a distorsiones, que clasificarse en dos categorías: hierro duro y suave. Las distorsiones por hierro duro son creadas por objetos que producen un campo magnético. Un altavoz o pieza de hierro magnetizado (por ejemplo, un altavoz o material magnético

unida físicamente al mismo marco de referencia del sensor). Las distorsiones por hierro suave se consideran desviaciones o alteraciones en el campo magnético existente, comúnmente es causada por metales como el níquel y el hierro.

E. Modelos para la corrección de errores

Para los tres sensores (acelerómetro, giroscopio y magnetómetro), los modelos de compensación resultante tienen la forma:

$$z_{output} = M_{a,g,m}(z_{input} - b_{a,g,m}) \quad (1)$$

donde M es una matriz de 3×3 que representa la corrección por factor de escala y desalineamiento de ejes (para el acelerómetro y giroscopio), para el magnetómetro representa la corrección por hierro suave, y el vector columna b de 3×1 representa el sesgo del sensor (acelerómetro y giroscopio), corrección por hierro duro para el magnetómetro, z_{output} es la salida del sensor calibrado, z_{input} es la salida del sensor sin calibrar, y los subíndices a , g y m indican el sensor del cual provienen las medidas (a para el acelerómetro, g para el giroscopio y m para el magnetómetro).

Para el caso del acelerómetro y giroscopio, las matrices M y b pueden ser determinados por ajuste de mínimos cuadrados o filtro de Kalman de los pares de entrada [1], esto facilita la calibración en tiempo real (online). Para el caso del magnetómetro, usaremos un algoritmo proporcionado en [6] por Yuri Petrov implementado en MATLAB, esta calibración se realiza offline.

IV. FUSIÓN DE SENSORES

En [7] fusión de datos se define como: “un proceso de múltiples niveles y fases de detección automática, que tratan con la asociación, correlación, estimación y combinación de datos e información de una o múltiples fuentes para lograr posiciones de refinado, estimaciones de identidad, evaluaciones completas, situaciones de amenazas oportunas a su significado”.

Uno de los algoritmos de fusión más populares es el Filtro de Kalman, su concepto y su funcionamiento se detallan en la siguiente sección.

A. Filtro de Kalman

El filtro de Kalman es un algoritmo desarrollado por Rudolf E. Kalman en 1960. En [8], se presenta su formulación original. Según [5], el filtro de Kalman es un estimador de lo que se llama “un problema cuadrático lineal”, que es un problema de estimar el “estado” instantáneo de un sistema dinámico lineal perturbado por ruido blanco gaussiano, mediante el uso de medidas correlacionadas linealmente con el estado, pero corrompidas por el ruido blanco. El estimador resultante es estadísticamente óptimo con respecto a cualquier función cuadrática de error de estimación.

Es un algoritmo recursivo, puede correr en tiempo real usando únicamente las mediciones de entrada actuales, el estado calculado previamente y su matriz de incertidumbre.

Opera por medio de un mecanismo de predicción y corrección. En esencia, el algoritmo pronostica el nuevo estado a partir de su estimación previa, añadiendo un término de corrección proporcional a la diferencia entre la medición y la predicción [9].

Se tomó como base de estudio para el algoritmo [9]. Se parte del modelo del sistema, que describe la evolución en el tiempo de la cantidad que se quiere estimar. Esto se representa mediante una ecuación en diferencias lineal estocástica de la siguiente forma:

$$x_k = \Phi_{k-1}x_{k-1} + \Gamma u_{k-1} + w_{k-1} \quad (2)$$

donde:

x_k es el vector de estados de dimensión $nx1$

Φ_{k-1} es la matriz de transición de estados. Esta matriz relaciona el vector de estados de un tiempo anterior $k-1$ con el vector de estados actual en el tiempo actual k . Su dimensión es nxn .

u_{k-1} entrada conocida del sistema.

Γ matriz que asocia la entrada con el proceso.

w_{k-1} ruido del proceso con media cero y matriz de covarianza Q .

Luego, se describe el modelo de la medición, dada por la siguiente ecuación:

$$z_k = H_k x_k + v_k \quad (3)$$

donde:

z_k es el vector de mediciones de dimensión $rx1$.

H_k es la matriz de observación de las mediciones de dimensión rxn . Esta matriz relaciona el vector de estados x_k con el vector de mediciones z_k .

v_k es el ruido del proceso con media cero y matriz de covarianza R .

Para este trabajo, consideraremos que las matrices Φ_k , H_k y la matriz de covarianza R son constantes, y que la entrada u_k es cero.

Como se mencionó anteriormente, el filtro opera por medio de un mecanismo de predicción-corrección. El $(-)$ en las ecuaciones (4) y (5) indica los valores a priori de las variables (antes de que se use la información de la medición) y $(+)$ en las ecuaciones (6) al (7) indica los valores a posteriori de las variables (después de que se usa la información de la medición), las ecuaciones correspondientes a cada etapa se presentan a continuación:

1) Ecuaciones de predicción

Las ecuaciones de predicción o estimación a priori son las siguientes:

$$\hat{x}_k(-) = \Phi \hat{x}_{k-1}(+) \quad (4)$$

$$P_k(-) = \Phi P_{k-1}(+) \Phi^T + Q_{k-1} \quad (5)$$

En esta etapa, se proyectan los estados de un instante de tiempo anterior utilizando la matriz de transición de estados (Φ), además, se propaga la incertidumbre de la estimación previa al estado actual utilizando el modelo del sistema y la covarianza de la perturbación aleatoria del proceso (Q_{k-1}).

2) Ecuaciones de corrección

Las ecuaciones de corrección o de actualización de la medida (también llamado estimación a posteriori) están dadas por:

$$\bar{K}_k = P_k(-)H^T(HP_k(-)H^T + R)^{-1} \quad (6)$$

$$\hat{x}_k(+) = \hat{x}_k(-) + \bar{K}_k(z_k - H\hat{x}_k(-)) \quad (7)$$

$$P_k(+) = P_k(-) - \bar{K}_k H P_k(-) \quad (8)$$

Esta etapa del filtro es la encargada de incorporar las nuevas mediciones del proceso, para producir una estimación con la menor varianza; primeramente, se calcula la ganancia de Kalman (6), a partir de la incertidumbre de la predicción de los estados $P_k(-)$ y de la covarianza de la perturbación aleatoria (R), luego se hace una estimación a posteriori, en donde se corrige la estimación a priori usando el valor de la medición z_k con la ganancia de Kalman \bar{K}_k ; finalmente se actualiza la incertidumbre asociada a la estimación a posteriori con la ecuación (8).

La operación del filtro se puede resumir en el siguiente diagrama:

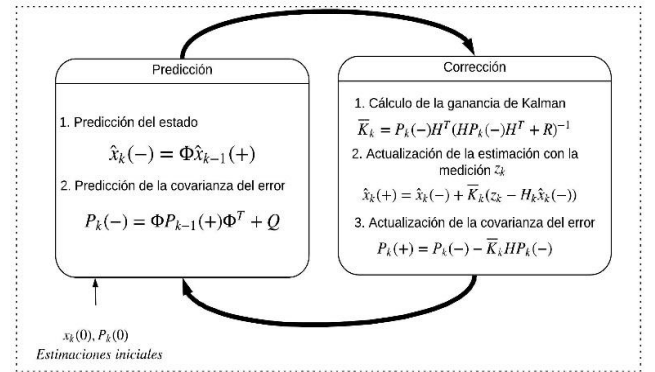


Fig 1. Diagrama del modelo del filtro de Kalman discreto.

V. DISEÑO, SIMULACIÓN E IMPLEMENTACIÓN

A. Diseño de software

El diseño del programa está basado en un patrón de diseño denominado “máquina de estados” el cual consiste en una estructura de casos embebida en un bucle. Esta arquitectura permite ejecutar código diferente cada vez que se ejecuta el bucle, en función de alguna condición. Resulta útil para nuestra aplicación, debido a que tenemos estados que se deben ejecutar antes de fusionar la información de los sensores, como la calibración de los mismos, que luego ya no se ejecutarán.

El diagrama de transición de estados de la máquina de estados implementada, se muestra en la Fig. 2.

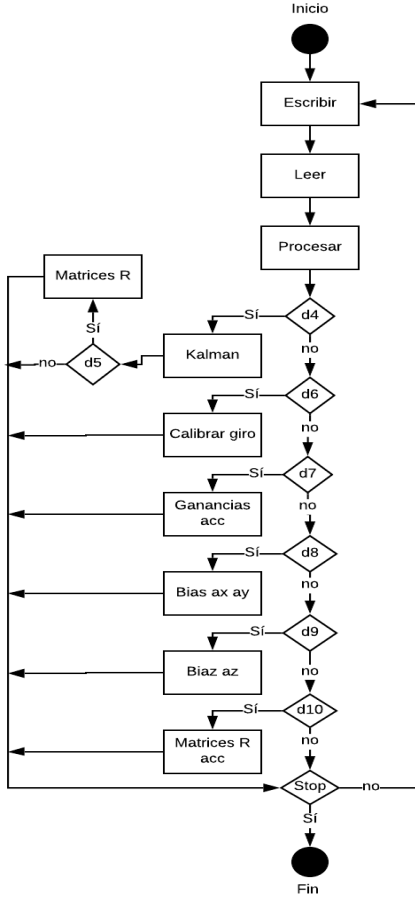


Fig. 2. Diagrama de transición de estados para este proyecto.

Consta de diez estados y de ocho entradas digitales (d4 al d10 y Stop), las entradas digitales d4 al d10 son para ejecutar cada estado de manera individual, la última entrada digital (Stop), es para finalizar la ejecución del programa, cada estado se describe brevemente a continuación.

Escribir, solicita los datos a los sensores. Leer, lee los datos de cada sensor. Procesar, corrige los datos de cada sensor con los modelos presentados en la sección IV-B. Kalman (d4), es el estado encargado de realizar la fusión para la estimación de los ángulos de Euler, Pitch (θ), Roll (ϕ) y Yaw (ψ). Matrices R (d5), se encarga de calcular las matrices de covarianza para su uso en el filtro de Kalman. Calibrar Giro (d6), calcula la matriz b_g mediante el método de mínimos cuadrados, para el giroscopio. Ganancias acc (d7), calcula la matriz M_a para el acelerómetro, se utilizó el filtro de Kalman para ello. Bias ax ay (d8), se encarga del cálculo de las componentes x e y, de la matriz b_a mediante el método de mínimos cuadrados. Bias az (d9), se encarga del cálculo de las componentes z de la matriz b_a mediante el mismo método, este cálculo se realiza en un estado independiente del cálculo de las componentes x e y debido a que se requiere que el sensor esté en una posición distinta. Matrices R acc (d10),

calcula la matriz de covarianza R necesaria para la implementación del filtro de Kalman utilizada para hallar la matriz M_a para el acelerómetro.

B. Simulación del filtro de Kalman de una variable

Resulta útil el diseño de una simulación para filtrar ruido de mediciones de una constante, esto, debido a que se pueden manipular las variables que intervienen en las ecuaciones del filtro de Kalman, y así determinar su influencia sobre la estimación resultante, además, se conocen claramente las características del ruido y el valor real de la constante a ser estimada, de esta manera, se puede evaluar el rendimiento, calculando el error cuadrático medio (error RMS) entre el valor real y la estimación.

Los modelos del proceso y de la medición son los siguientes:

$$x_k = c + w_k \quad (9)$$

$$z_k = c + v_k \quad (10)$$

De esta manera, $\Phi = 1$, suponemos que la constante se mide directamente, por lo tanto, $H = 1$.

Las ecuaciones del filtro de Kalman quedan de la siguiente manera:

i. Estimación a priori

$$\hat{x}_k(-) = \hat{x}_{k-1} \quad (11)$$

$$P_k(-) = P_{k-1}(+) + Q \quad (12)$$

ii. Estimación a posteriori

$$\bar{K}_k = \frac{P_k(-)}{P_k(-) + R} \quad (13)$$

$$\hat{x}_k(+) = \hat{x}_k(-) + \bar{K}_k(z_k - \hat{x}_k(-)) \quad (14)$$

$$P_k(+) = (1 - \bar{K}_k)P_k(-) \quad (15)$$

Para este caso, tenemos la certeza de que estamos midiendo una constante, por lo tanto, la matriz de covarianza del proceso es cero ($Q = 0$), pero en este caso, haremos que pruebas con distintos valores, para ver su efecto sobre el algoritmo. Los valores iniciales del vector de estado \hat{x}_0 y de la matriz de incertidumbre P_0 pueden seleccionarse arbitrariamente, se sabe por [6], que las ecuaciones (6) al (8) representan un sistema asintóticamente estable, y, por lo tanto, la estimación del estado \hat{x}_k se vuelve independiente de la estimación inicial a medida que k aumenta.

C. Fusión de datos

La estructura básica de la fusión implementada es la siguiente:

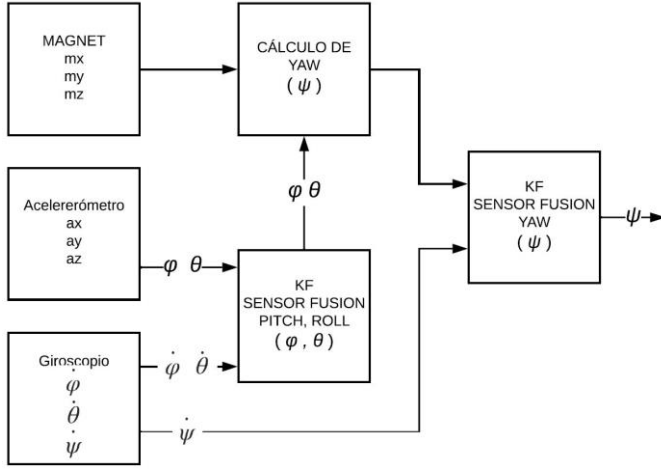


Fig. 3. Estructura de la fusión de datos.

Para el cálculo de los ángulos Pitch (θ) y Roll (ϕ), se fusionan los datos provenientes del acelerómetro y del giroscopio. Primeramente, se calculan los ángulos θ y ϕ a partir de la lectura del acelerómetro, utilizando las relaciones trigonométricas entre los ejes y el vector gravedad, mediante las siguientes fórmulas:

$$\theta = -\arctan\left(\frac{ax}{\sqrt{ay^2 + az^2}}\right) \cdot \text{sign}(az) \quad (16)$$

$$\phi = -\arctan\left(\frac{ay}{az}\right) \quad (17)$$

Estas relaciones son válidas cuando el vehículo está en reposo o con velocidad constante, cuando el vehículo sufre aceleraciones, las lecturas no son válidas, es por esto que debemos fusionar estos ángulos con los datos del giroscopio.

El cálculo del ángulo Yaw (ψ) es resultado de la fusión del ángulo calculado con el magnetómetro y con el giroscopio.

Para el cálculo de Yaw (ψ), con el magnetómetro, se debe proyectar las componentes x e y sobre el plano horizontal, utilizando las matrices de rotación [3], luego, ψ viene dada por:

$$\psi = -\arctan\left(\frac{-m_{yh}}{m_{xh}}\right) \quad (18)$$

donde:

$$m_{yh} = m_y \cos \phi_{KF} - m_z \sin \phi_{KF}$$

$$m_{xh} = m_x \cos \theta_{KF} + m_y \sin \phi_{KF} \sin \theta_{KF} + m_z \cos \phi_{KF} \sin \theta_{KF}$$

Los ángulos θ_{KF} y ϕ_{KF} , son los ángulos calculados a partir de la fusión del acelerómetro con el giroscopio, como se indica en la Fig. 3.

Las lecturas del giroscopio vienen dadas en el sistema de referencia del vehículo (Body). Para su utilización en el filtro, debemos tener las lecturas en el sistema de referencia de navegación, para ellos utilizamos las relaciones entre los ejes descripta en [10], en el que utilizamos los ángulos calculados en (16) y (17).

$$\begin{bmatrix} \dot{\phi} \\ \dot{\theta} \\ \dot{\psi} \end{bmatrix} = \begin{bmatrix} 1 & \sin \phi \tan \theta & \cos \phi \tan \theta \\ 0 & \cos \theta & -\sin \phi \\ 0 & \sin \phi \sec \theta & \cos \phi \sec \theta \end{bmatrix} \begin{bmatrix} p \\ q \\ r \end{bmatrix} \quad (19)$$

Siendo p , q y r las lecturas adquiridas del giroscopio, ya calibradas.

D. Filtro de Kalman para estimar los ángulos Pitch (θ), Roll (ϕ) y Yaw (ψ)

Debido a que el algoritmo para la fusión de datos es similar para los tres ángulos (solamente se diferencian en las matrices Q y R para cada caso), se detallará de manera genérica la fusión, sobre una variable elegida arbitrariamente (α) y su derivada ($\dot{\alpha}$), (que representan el ángulo y la velocidad angular para cada caso).

El vector de estados será el siguiente:

$$x_k = \begin{bmatrix} \alpha_k \\ \dot{\alpha}_k \end{bmatrix} \quad (20)$$

El modelo del proceso se representa por la siguiente ecuación en diferencias lineal estocástica:

$$\begin{bmatrix} x_k \\ \dot{\alpha}_k \end{bmatrix} = \begin{bmatrix} 1 & \Delta T \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \alpha_{k-1} \\ \dot{\alpha}_{k-1} \end{bmatrix} + w_{k-1} \quad (21)$$

donde w representa el ruido del proceso con media cero y matriz de covarianza Q . Según [2], para la matriz Φ dada en (21), le corresponde la siguiente matriz Q :

$$Q_k = q \begin{bmatrix} \frac{(\Delta T)^3}{3} & \frac{(\Delta T)^2}{2} \\ \frac{(\Delta T)^2}{2} & \Delta T \end{bmatrix} \quad (22)$$

donde q es la covarianza del ruido del proceso en tiempo continuo y ΔT es el tiempo de iteración del algoritmo. El valor de q se ajusta manualmente mediante prueba y error [11].

El vector de medición está dado por:

$$\begin{bmatrix} z_k \\ \dot{\alpha}_k \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \alpha_k \\ \dot{\alpha}_k \end{bmatrix} + v_k \quad (23)$$

donde v es el ruido de las mediciones con media cero y matriz de covarianza R .

La matriz de covarianza R de las mediciones está dada por:

$$R = \begin{bmatrix} \sigma_\alpha^2 & \sigma_\alpha \sigma_{\dot{\alpha}} \\ \sigma_\alpha \sigma_{\dot{\alpha}} & \sigma_{\dot{\alpha}}^2 \end{bmatrix} \quad (24)$$

donde σ_α^2 y $\sigma_{\dot{\alpha}}^2$ son las varianzas de los ruidos de las mediciones α y $\dot{\alpha}$ respectivamente, $\sigma_\alpha \sigma_{\dot{\alpha}} = \sigma_{\dot{\alpha}} \sigma_\alpha$ son las covarianzas de las mediciones.

Con estas matrices definidas, se puede implementar el filtro de Kalman utilizando las ecuaciones (4) al (8).

VI. PRUEBAS Y RESULTADOS

Se realizan las pruebas, con las simulaciones diseñadas anteriormente variando los parámetros, principalmente la matriz de covarianza R , para lograr el comportamiento deseado en la fusión, también se presentan los resultados alcanzados con la fusión para estimar los ángulos deseados.

A. Resultados de la simulación del filtro de Kalman para una variable

En esta sección se presentan los resultados de la implementación de la simulación diseñada en VII-B. El diseño de la interfaz permite que se pueda modificar los parámetros Q , R , x_0 , P_0 y se puede visualizar el error RMS, tanto del filtro, como de las mediciones sin el filtro, de manera a comprobar su efectividad. La interfaz de usuario se muestra en la Fig. 4.

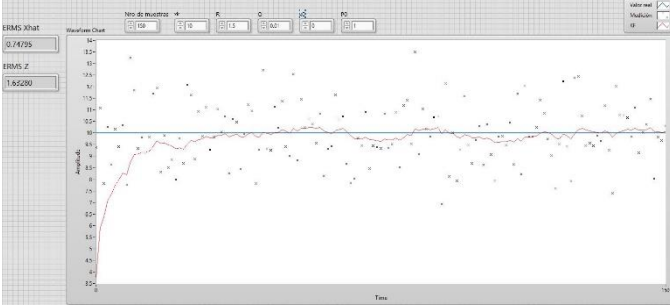


Fig. 4. Interfaz de usuario de la simulación de filtro de Kalman.

En las siguientes tablas, podemos ver la influencia de los parámetros Q y R sobre la eficiencia del filtro, manteniendo constantes las demás variables ($x_k = 10$, $x_0 = 0$, $P_0 = 1$), el número de muestras es 150.

TABLA I
ERRORES RMS CON $Q = \text{CTE}$. Y R VARIABLE

Q	R	ERMS KF	ERMS medición
0.2	0.25	0.14186	0.24519
0.2	0.5	0.21237	0.51645
0.2	1	0.39957	1.09777
0.2	1.25	0.42984	1.29836
0.2	1.5	0.59537	1.80550

TABLA II
ERRORES RMS CON $Q = \text{VARIABLE}$ Y $R = \text{CTE}$.

Q	R	ERMS KF	ERMS medición
0.1	0.5	0.09052	0.42115
0.05	0.5	0.07717	0.51715
0.001	0.5	0.00875	0.49620
0.0005	0.5	0.00701	0.49013
0.0001	0.5	0.00403	0.48012

A partir de estos datos, podemos ver la eficiencia del filtro de Kalman, mediante el cual se reduce en todos los casos, el error RMS, como Q representa la varianza de la incertidumbre del

proceso, y sabemos que estamos midiendo una constante, el filtro resulta más efectivo a medida que $Q \rightarrow 0$, también vemos que al ir aumentando la incertidumbre de la medición R la predicción gana más peso, reduciendo significativamente el error.

B. Resultados de las fusiones Pitch y Roll

Debido a que los resultados para ambos ángulos son similares, se presentará el resultado de la fusión de uno de ellos, se ha seleccionado el ángulo Roll (ϕ).

Primeramente, se ha hecho las pruebas con el cálculo de la matriz de covarianza de las mediciones R con el vehículo en reposo, y se obtuvo una buena lectura de las inclinaciones, pero una mala respuesta cuando el vehículo se somete a aceleraciones distintas al de la gravedad, debido a que las ecuaciones (16) y (17) solo son válidas para el vehículo en reposo.

La R calculada con el vehículo en reposo es la siguiente:

$$R_1 = \begin{bmatrix} 0.0646613 & 0 \\ 0 & 0.108575 \end{bmatrix}$$




Fig. 5. Respuesta del filtro con R_1 ante aceleraciones horizontales.

Con el vehículo sometido a aceleraciones horizontales vemos el error que genera la lectura del ángulo del acelerómetro, al tener una varianza pequeña del error, el filtro da fiabilidad a estas lecturas, y no puede ignorar esas aceleraciones, que es lo que queremos conseguir en este proyecto. Estos resultados no son satisfactorios para el objetivo deseado, debido a esto, se calcula la matriz de covarianza de las mediciones R con el vehículo sometido a aceleraciones horizontales y luego se realiza un ajuste manual mediante prueba y error para conseguir un resultado satisfactorio. La R calculada se muestra a continuación con el resultado de la implementación en la Fig. 6.

$$R_2 = \begin{bmatrix} 24.5 & 0 \\ 0 & 2.7812 \end{bmatrix}$$

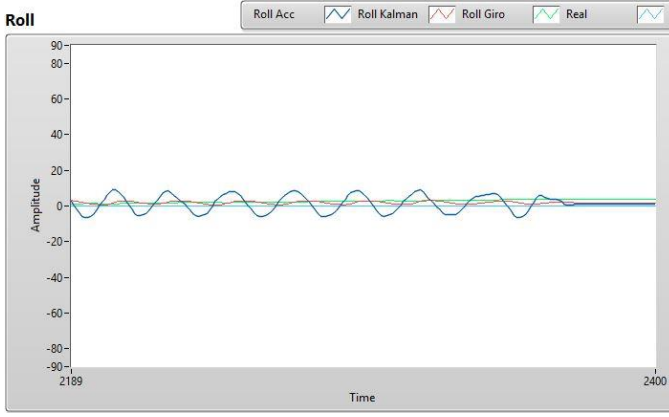


Fig. 6. Respuesta del filtro con R_2 ante aceleraciones horizontales.

El uso de esta R se acerca a lo deseado, aunque no ignora completamente, reduce en gran medida la oscilación de ángulo Roll (ϕ).

C. Fusión Yaw

Una vez obtenidos los ángulos Pitch y Roll, se puede calcular Yaw a partir de la lectura del magnetómetro (ψ) utilizando la ecuación (18), este ángulo se fusiona con la lectura del giroscopio ($\dot{\psi}$) obtenida de la ecuación (19).

Se procede de manera similar a la fusión para calcular los ángulos Pitch y Roll, primeramente, se calcula la matriz R tomando una cierta cantidad de datos, y calculando la varianza de las mediciones, luego se somete el sensor a disturbios magnéticos (causado con un pequeño imán permanente) para ver el comportamiento de la fusión, finalmente, se realiza un ajuste manual, hasta que alcance el comportamiento deseado.

R calculada con el vehículo sin estar sometido a distorsiones magnéticas:

$$R_1 = \begin{bmatrix} 0.0295689 & 0 \\ 0 & 0.00035017 \end{bmatrix}$$

Los resultados se ven en la Fig. 7.




Fig. 7. Respuesta de la fusión Yaw con R_1 sin distorsiones magnéticas.

Se puede notar la mejoría que introduce el giroscopio, suavizando la curva, y la componente del magnetómetro contribuye a que no haya errores acumulativos (propias del giroscopio). Pero presenta problemas ante la presencia de distorsiones magnéticas como se puede ver en la Fig. 8.




Fig. 8. Respuesta de la fusión Yaw con R_1 con distorsiones magnéticas.

Queda claro que la distorsión magnética no afecta al giroscopio, en cambio, afecta en gran medida a la lectura del magnetómetro y a salida del filtro de Kalman.

Para mejorar estos datos, hacemos un ajuste manual, de manera a darle mayor peso la lectura del giroscopio, aumentando la varianza de la medición del magnetómetro, de manera a que sea más robusta en ambientes con perturbaciones magnéticas.

Con varios ensayos de prueba y error, se llega al siguiente valor de R :

$$R_2 = \begin{bmatrix} 29 & 0 \\ 0 & 2 \end{bmatrix}$$

Los resultados se pueden ver en la Fig. 9.

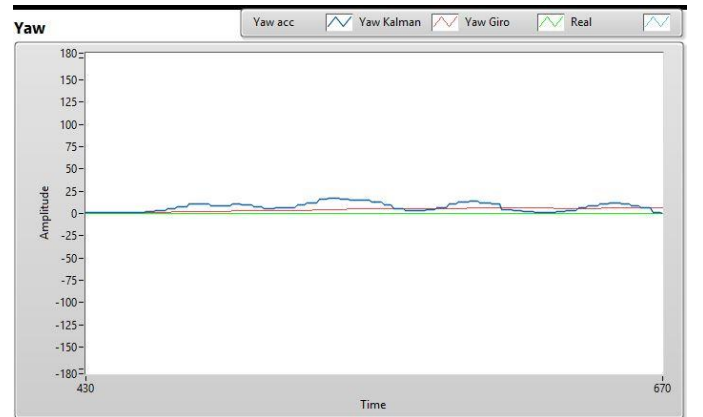


Fig. 9. Respuesta de la fusión Yaw con R_2 con distorsiones magnéticas.

Con esto se consigue un comportamiento adecuado para el entorno de aplicación de la fusión.

Dependiendo del entorno de aplicación, se pueden escoger los valores de R adecuados.

VII. CONCLUSIONES

Resulta indiscutible la importancia de la fusión de datos de distintos sensores para obtener la calidad adecuada de las mediciones de las variables que deben ser procesadas, conforme a lo que se ha expuesto en este trabajo. Y en efecto, mediante este procedimiento se logra la utilización de sensores de bajo costo para usarlas mediante la combinación de sus datos y de

este modo funcionan como los dispositivos de alta calidad, pero a un costo mucho más bajo.

El análisis del comportamiento del algoritmo mediante simulaciones sirvió para determinar cómo influyen distintos parámetros en la calidad de las estimaciones.

Como resultado de la presente investigación se pudo fusionar los sensores (acelerómetro, giroscopio y magnetómetro) de manera correcta y se obtuvo datos más que fueron más robustos a perturbaciones externas, que permitió extraer la información más relevante y exacta posible, a partir de esto se pudo planificar y ejecutar acciones para hacer posible la navegación de un vehículo autónomo.

En efecto, en la competencia internacional de vehículos autónomos a escala Robocar Race (2018) [12] llevada a cabo en la ciudad de San Pablo - Brasil, organizada por la Facultad de Tecnología de Santo André, Universidad Federal ABC y Robótica Paula Souza (Robocar Race, 2018) en la cual se ha participado en representación de la Universidad Católica Nuestra Señora de la Asunción, sede Regional Alto Paraná, Facultad de Ciencias y Tecnología, la participación del equipo ha sido exitosa, pues se logró:

- Segundo puesto en la calidad del TDP (Technical Description Paper), el artículo de descripción técnica será publicada en la prestigiosa revista JPAUT (Journal of Production and Automation) de Brasil.
- Cuarto lugar en la competencia (categoría libre).

Además, se ha participado en la competencia Labview Student Design Competition, y como resultado, la National Instruments ha invitado al equipo principal de A2G al evento NIWeek 2019. Dicho evento tiene una duración de cuatro días, en ese tiempo son desarrollados sesiones técnicas, conferencias, pueden ser observados los proyectos desarrollados por ingenieros de la empresa o asociados a él, entre otros.

REFERENCIAS

- [1] G. Mohinder S. y A. Angus P., Kalman Filtering: Theory and Practice Using MATLAB, Fourth ed., Hoboken, New Jersey: JOHN WILEY & SONS, INC., 2015.
- [2] R. Areny, Sensores y acondicionadores de señal, Marcombo, 2004.
- [3] D. P. Vigouroux Cavolina, Implementación de unidad de mediciones inerciales (IMU) para robótica utilizando filtro de Kalman, Sartenejas, 2010.
- [4] L. VectorNav Technologies, «VectorNav Technologies LLC,» [En línea]. Available: <https://www.vectornav.com/support/library/magnetometer>. [Último acceso: 28 Marzo 2019].
- [5] G. Mohinder y A. Andrews, Kalman filtering, Theory and Practice using Matlab, JohnWiley & Sons, 2008.
- [6] Y. Petrov, «Ellipsoid fit,» 04 12 2015. [En línea]. Available: <https://es.mathworks.com/matlabcentral/fileexchange/24693-ellipsoid-fit>. [Último acceso: 22 10 2018].
- [7] D. Hall y L. James, «An introduction to multisensor data fusion,» *IEEE*, vol. 85, n° 1, pp. 6-23, 1997.
- [8] R. E. Kalman, «A new aproach to linear filter and prediction theory,» *J. Basic Eng. D.*, vol. 82, pp. 35-45, 1960.
- [9] G. Prado, «Técnicas recursivas para estimación dinámica: una introducción matemática al filtro de Kalman,» 2005.

- [10] R. Amezcua Paredes y A. G. Pineda Salgado, «Sistema de referencia inercial: análisis de funcionamiento, fundamentos y evolución,» México D.F., 2012.
- [11] M. Huerta, «Implementación de un sistema de determinación de orientación mediante diseño SOPC en una FPGA para vehículo aéreo no tripulado del tipo quadrotor,» Perú, 2015.
- [12] Robocar Race, «Robocar Race,» [En línea]. Available: <http://www.roborace.com.br/>. [Último acceso: 2018].